

Charades 测试结果报告

更新时间：2026-06-10

1. 测试目的

本报告总结当前 ActionLens 方案在 Charades 数据上的一次阶段性测试结果。

当前被测试的是：

Charades clip
-> Stage2 规则检测
-> VLM 全视频/事件复核
-> 结果融合

其中 TAL / ActionFormer 目前只完成了数据适配与 smoke test，还没有进入真实 SlowFast 特征训练，因此本报告的主要结果来自 规则 + VLM 融合方案。

2. 数据与设置

测试数据：

- 数据集：Charades
- 测试规模：50 个 clip
- 视频数：50 个 unique videos
- 动作覆盖：19 个 canonical actions
- 输入清单：outputs/charades_clips_50.csv
- 批量输出目录：outputs/charades_clip_batch_50/

主要输出文件：

- outputs/charades_clip_batch_50/batch_summary.json
- outputs/charades_clip_batch_50/aggregation_report.json
- outputs/charades_clip_batch_50/aggregation_report.md
- outputs/charades_clip_batch_50/pending_event_review_summary.json

3. 总体结果

3.1 批处理状态

```
| 指标 | 数值 |  
| --- | ---: |  
| total_clips | 50 |  
| stage2_ok | 50 |  
| vlm_ok | 50 |  
| fused_ok | 50 |  
| stage2_event_hits | 19 |  
| stage2_event_rate | 0.38 |  
| vlm_present_hits | 26 |  
| vlm_present_rate | 0.52 |
```

结论：

- 50 个 clip 全部完成 Stage2、VLM 和融合流程。
- Stage2 规则在 50 个 clip 中命中 19 个，命中率为 38%。
- VLM 在 50 个 clip 中确认存在目标行为 26 个，确认率为 52%。

3.2 融合结果

```
| 指标 | 数值 |  
| --- | ---: |  
| total_fused_events | 115 |  
| unique_videos | 50 |  
| unique_actions | 19 |  
| unique_actions_with_outputs | 16 |  
| final_events | 20 |  
| semantic_candidates | 24 |  
| pending_events | 0 |  
| rejected_events | 71 |
```

解释：

- final_events：规则、Charades 标注、VLM 证据较一致的最终事件。
- semantic_candidates：规则没有稳定检出，但 Charades/VLM 提供语义证据的候选事件。
。
- rejected_events：规则疑似误报，经 VLM 或融合逻辑否定。
- pending_events：需要进一步复核但尚未处理的事件；本轮已全部清零。

4. 动作级别结果

4.1 支持较好的动作

Action	Charades GT clips	Final	Semantic	Stage2 hits	VLM present	Rejected
---	---	---	---	---	---	---
drinking_water	11	15	1	59	8	44
talking_on_phone	3	5	2	32	0	27
eating	13	0	4	0	0	0
holding_phone	11	0	3	0	0	0
looking_at_phone	7	0	2	0	0	0
sitting_on_chair	10	0	2	0	0	0

观察：

- 当前规则最能产生时间段事件的是 drinking_water 和 talking_on_phone。
- eating、holding_phone、looking_at_phone 等动作主要依赖 Charades 标注和 VLM 语义补充，还没有形成稳定的规则事件。
- drinking_water 和 talking_on_phone 虽然 final 数量较高，但 rejected 也高，说明规则召回较强但误报明显。

4.2 暂无输出的动作

Action	Charades GT clips	Final	Semantic	Stage2 hits	Rejected
---	---	---	---	---	---
running	4	0	0	0	0
sitting_on_floor	7	0	0	0	0
standing_up	14	0	0	0	0

这些动作对当前规则体系不友好：

- running 更依赖运动轨迹和速度特征。
- standing_up / sitting_on_floor 更依赖姿态时序变化。
- 这类动作更适合交给 TAL / ActionFormer 或更强的姿态时序模型处理。

5. 与 batch20 的对比

指标	batch20	batch50	变化
---	---	---	---
total_clips	20	50	+30
stage2_event_hits	9	19	+10
stage2_event_rate	0.45	0.38	-0.07
vlm_present_hits	5	26	+21
vlm_present_rate	0.25	0.52	+0.27
total_fused_events	31	115	+84
unique_actions_with_outputs	4	16	+12
final_events	6	20	+14
semantic_candidates	4	24	+20
rejected_events	21	71	+50

结论：

- 扩展到 50 个 clip 后，动作覆盖明显提升：有输出的动作从 4 类增加到 16 类。
- VLM 的语义补充能力更明显，vlm_present_rate 从 25% 提升到 52%。
- Stage2 规则命中率略降，说明当前规则泛化不足。
- rejected 数量增加，主要来自 drink / phone 规则误报。

6. 当前方案结论

当前 Charades batch50 测试说明：

1. 工程链路已经跑通：50 个 clip 全部完成 Stage2、VLM、融合与聚合。2. 规则基线可作为初始事件生成器：对喝水、打电话等人-物交互动作有效，但误报较多。3. VLM 对泛化有明显帮助：能补充规则无法覆盖的语义动作，也能否定一部分规则误报。4. 规则方法不能覆盖全部 Charades 动作：尤其是 running、standing_up、sitting_on_floor 等姿态/运动时序动作。5. 下一阶段需要 TAL / ActionFormer：当前 ActionFormer 已完成 Charades adapter、split、feature smoke 和 GPU 执行包，待 4090 上生成真实 SlowFast 特征后进入训练 smoke。

7. TAL / ActionFormer 当前状态

TAL 侧已经完成：

- external/actionformer_release/libs/datasets/charades.py
- external/actionformer_release/configs/charades_smoke.yaml
- external/actionformer_release/configs/charades_slowfast.yaml
- scripts/tal/extract_slowfast_features.py
- scripts/tal/check_slowfast_backend.py
- docs/TAL_4090_EXECUTION_PACKAGE.md

本机 smoke 结果：

```
| 指标 | 数值 |
| --- | --- |
| dataloader smoke total | 50 |
| dataloader ok | 50 |
| feature dim | 2304 |
| feature length range | 38 - 207 |
| total GT segments | 148 |
| ActionFormer sample feats | `[2304, 91]` |
| ActionFormer sample segments | `[5, 2]` |
| train-loss smoke final_loss | 0.30324 |
```

注意：

- 当前 features_smoke 只是格式验证特征，不能代表真实识别性能。
- ActionFormer 尚未训练，不能用 smoke 输出作为模型效果结论。
- 下一步应在 4090 上先跑 `check_slowfast_backend.py --device cuda`，再做 `slowfast-r50 --limit 1`。

8. 后续建议

短期建议：

1. 在 4090 上修好 PyTorch CUDA / PyTorchVideo 环境。
2. 跑 SlowFast 后端自检。
3. 先提取 1 个 Charades clip 的真实 SlowFast 特征。
4. limit1 成功后提取 50 个真实特征。
5. 跑真实特征 dataloader smoke。
6. 进入 ActionFormer 1 epoch 训练 smoke。

中期建议：

- 用 ActionFormer 作为 Stage3 时序动作定位模块。
- 将 Stage3 输出接入现有融合逻辑，形成：

Stage2 rules + Stage3 TAL + VLM review + Charades GT comparison

预期收益：

- 提高 running、standing_up、sitting_on_floor 等动作覆盖。
- 降低 drink / phone 规则对 VLM 复核的依赖。
- 形成规则基线 vs TAL 模型的可量化 A/B 对比。